

Практическое задание: Анализ данных такси

Курс: ИИ и МО в транспортной отрасли

Задание (30-40 минут)

Используя данные о поездках такси NYC выберите другой месяц отличный от января и февраля, выполните следующие задачи:

Задача 1: Загрузка и анализ (10 мин)

С помощью Dask: 1. Загрузите данные 2. Выведите количество записей и список колонок 3. Найдите среднее расстояние и среднюю стоимость поездки

Задача 2: Анализ по часам (10 мин)

1. Добавьте колонку `pickup_hour` (час начала поездки)
2. Найдите час с максимальным количеством поездок
3. Вычислите среднюю стоимость поездки по часам (какой час самый дорогой?)

Задача 3: Модель предсказания (15 мин)

1. Очистите данные: удалите записи с `trip_distance <= 0` или `total_amount <= 0`
2. Обучите модель линейной регрессии (`dask_ml.linear_model.LinearRegression`) для предсказания `total_amount` по признакам:
 - `trip_distance`
 - `pickup_hour`
3. Выведите R^2 модели и коэффициенты
4. Сделайте вывод: какой фактор влияет на стоимость сильнее?

Что отправить

Jupyter Notebook или скрипт `.py` с: - Кодом решения - Выводами результатов (`print`)

Подсказки

```
# Загрузка
import dask.dataframe as dd
ddf = dd.read_parquet('yellow_tripdata_2024-0*.parquet')

# Час из timestamp
ddf['pickup_hour'] = ddf['tpep_pickup_datetime'].dt.hour

# Группировка
result = ddf.groupby('pickup_hour').size().compute()
```

```
# Линейная регрессия
from dask_ml.linear_model import LinearRegression
model = LinearRegression()
model.fit(X, y)
```